

## 最小二乘法

### 1. 最小二乘法的原理:

目标函数 =  $\sum (\overset{\text{机器学习的 loss function}}{\text{观测值}} - \overset{\text{样本}}{\text{理论值}})^2$   
拟合函数的值

例: 线性回归  $(x^{(1)}, y^{(1)}) \dots (x^{(m)}, y^{(m)})$  每个  $x^{(i)}$  就一个特征  $x_1$ , 那么样本的拟合函数:  $h_\theta(x) = \theta_0 + \theta_1 x$

目标函数:  $J(\theta_0, \theta_1) = \sum_{i=1}^m (y^{(i)} - h_\theta(x^{(i)}))^2 = \sum_{i=1}^m (y^{(i)} - \theta_0 - \theta_1 x_1^{(i)})^2 \Rightarrow$  求出使  $J(\theta_0, \theta_1)$  最小值的  $\theta_0, \theta_1$ 。这样就得到了拟合函数。

### 2. 最小二乘法的代数解法.

$J(\theta_0, \theta_1)$  对  $\theta_0, \theta_1$  求导, 令其等于 0, 二元一次方程  $\Rightarrow \theta_0, \theta_1$

多个样本特征, 就是对  $J(\theta_0, \theta_1, \dots, \theta_n)$  求多次导, 令其等于 0, 得到  $n+1$  元一次方程, 得  $\theta_0, \dots, \theta_n$  的值。

### 3. 最小二乘法的矩阵求法.

多元线性回归:

假设函数:  $h_\theta(x_1, x_2, \dots, x_n) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n \Rightarrow h_\theta(X) = X\theta$   $X$  —  $(m \times n)$   $\theta$  —  $(n \times 1)$   $m$  — 样本个数,  $n$  — 样本的特征数。

损失函数:  $J(\theta) = \frac{1}{2} (X\theta - Y)^T (X\theta - Y)$   $Y$  样本输出向量  $Y$  —  $(m, 1)$

$$\frac{\partial J(\theta)}{\partial \theta} = X^T (X\theta - Y) = 0 \Rightarrow X^T X \theta = X^T Y \Rightarrow \theta = (X^T X)^{-1} X^T Y$$

### 4. 最小二乘法的局限性和使用场景

① 最小二乘法 需要计算  $X^T X$  的逆矩阵, 若逆矩阵不存在时, 就不能用最小二乘法了, 但仍可以用梯度下降。可以去掉冗余特征, 使  $X^T X$  的行列式不为 0, 然后用最小二乘法。

② 当特征  $n$  很大时  $X^T X$  逆矩阵求起来, 很难而且很慢。

③ 拟合函数不是线性的, 无法用最小二乘法? 需要用技巧将其转化  $(x_1, x_2, x_2^2)$  — 可能  $\theta$  表示为  $(X^T X)^{-1} X^T Y$